

最新事例紹介資料

2018/09/20

岐阜大学 加藤研究室 中塚俊介

目次

■ How good is my GAN ?

Konstantin Shmelkov, Cordelia Schmid, Karteek Alahari
<https://arxiv.org/abs/1807.09499> (ECCV2018)

■ GANomaly: Semi-Supervised Anomaly Detection via Adversarial Training

Samet Akcay, Amir Atapour-Abarghouei, Toby P. Breckon
<https://arxiv.org/abs/1805.06725>

■ Deep Anomaly Detection Using Geometric Transformations

Izhak Golan, Ran El-Yaniv
<https://arxiv.org/abs/1805.10917> (NIPS2018)


■ Generative Probabilistic Novelty Detection with Adversarial Autoencoders

Stanislav Pidhorskyi, Ranya Almohsen, Donald A Adjero, Gianfranco Doretto
<https://arxiv.org/abs/1807.02588> (NIPS2018)



How good is my GAN ?

- GAN-train (recall: diversity) と GAN-test (precision: quality) を提案
 - diversity と quality を別々に評価できる
 - Inception Network (with Imagenet) からの解放
- GANによるData Augmentation は識別精度が低下する可能性があることを示唆
 - P_g は P_r ほどの diversity と quality を持てない
 - Overfitting



2.5k, 5k, 10kのデータでGANを学習 & Augmentation後
識別モデルを学習したときの精度

Num real images	real C10	real+GAN C10	real C100	real+GAN C100
2.5k	73.4	67.0	25.6	23.9
5k	80.9	77.9	40.0	33.5
10k	85.8	83.5	51.5	45.5

精度の低下

精度の低下

詳しくは

<https://www.slideshare.net/ShunsukeNAKATSUKA1/how-good-is-my-gan>




GANomaly: Semi-Supervised Anomaly Detection via Adversarial Training

■ 仮定

- 正常データのみで学習
- G_E が $x \rightarrow z$ のmapping を学習できても、 G_D は完全な復元ができない
- 要は異常データを入力すると、
 z は異常ベクトルになっても、出力は正常データになってしまう

■ 入出力の特徴ベクトルで異常度を算出

- Network E を付与して、差を取ることが新規性



感想

- この仮定がそもそも正しいかを示す実験がない
- この仮定が正しいなら、
入出力もしくは z を見るだけで判定可能では？

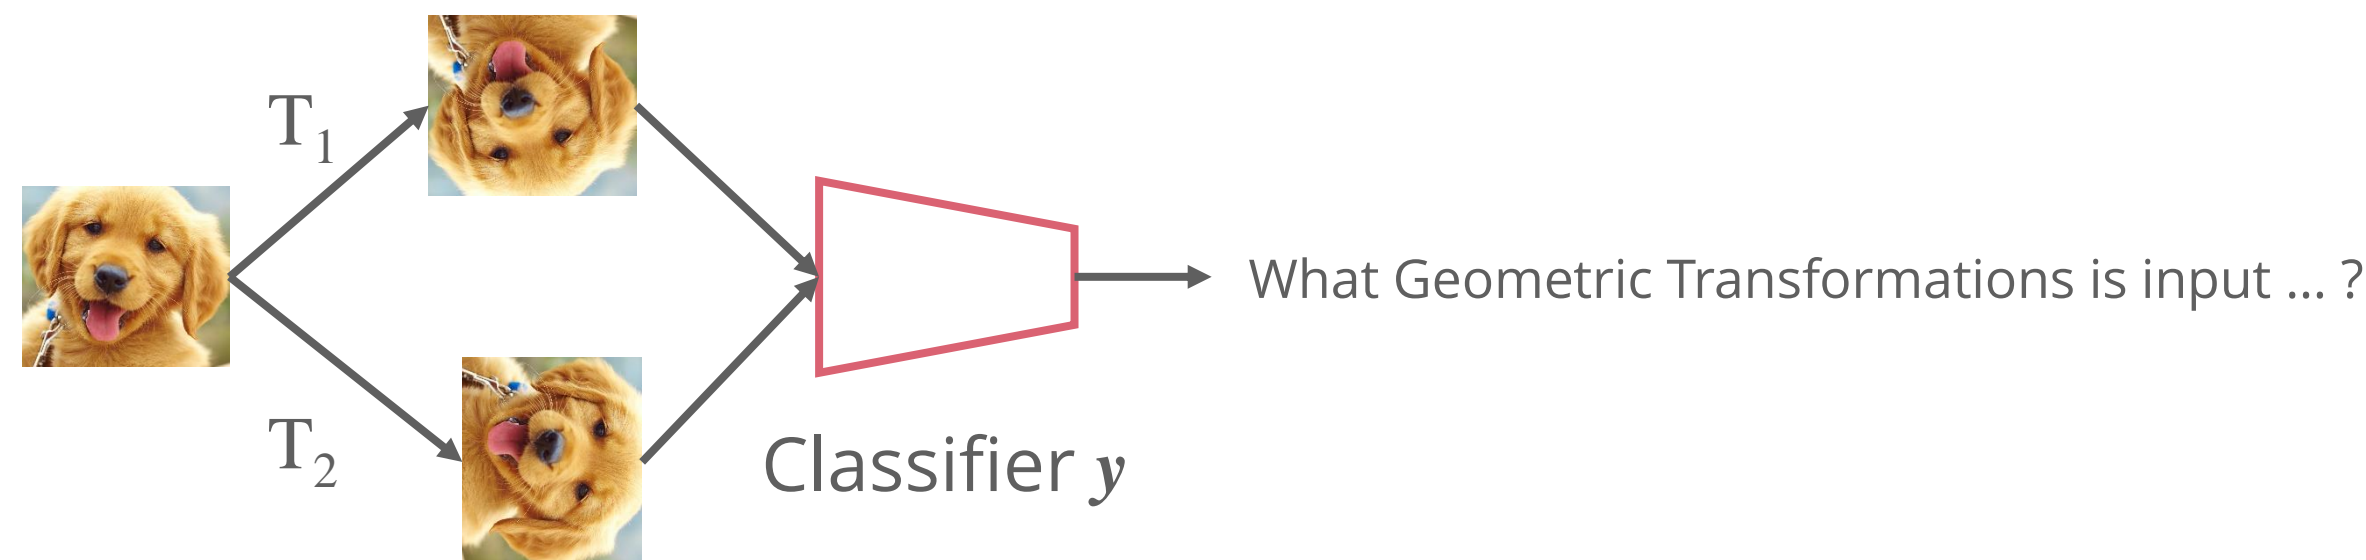
異常度

$$\left| G_E(x) - E(G(x)) \right|_1$$



Deep Anomaly Detection Using Geometric Transformations

- K 個の幾何変換の集合 $T = \{T_1, T_2, \dots, T_{K-1}\}$
 - 上下反転, 平行移動, 回転
- 正常画像に対して, 何らかの幾何変換 T_j をする
- 何の幾何変換がされたかの K クラス分類するNNを学習する



正常度



$$\frac{1}{k} \sum_{j=0}^{k-1} \left[y(T_j(x)) \right]_j$$

正常画像なら何の変換か分類できるので、
正常度が高くなる

Dataset	c_i	OC-SVM		DAGMM	DSEBM	AD-GAN	OURS
		RAW	CAE				
CIFAR-10 (32x32x3)	0	0.706	0.749	0.414±0.023	0.560±0.069	0.649	0.761±0.001
	1	0.513	0.517	0.571±0.020	0.483±0.018	0.390	0.911±0.003
	2	0.691	0.689	0.538±0.040	0.619±0.001	0.652	0.799±0.003
	3	0.524	0.528	0.512±0.008	0.501±0.004	0.481	0.738±0.002
	4	0.773	0.767	0.522±0.073	0.733±0.002	0.735	0.871±0.003
	5	0.512	0.529	0.493±0.036	0.605±0.003	0.476	0.873±0.002
	6	0.741	0.709	0.649±0.017	0.684±0.003	0.623	0.831±0.004
	7	0.526	0.531	0.553±0.008	0.533±0.007	0.487	0.949±0.001
	8	0.709	0.710	0.519±0.024	0.739±0.003	0.660	0.907±0.003
	9	0.506	0.506	0.542±0.058	0.636±0.031	0.378	0.876±0.003
	avg	0.620	0.624	0.531	0.609	0.553	0.852
CIFAR-100 (32x32x3)	0	0.680	0.684	0.434±0.039	0.640±0.002	0.631	0.714±0.002
	1	0.631	0.636	0.495±0.027	0.479±0.001	0.549	0.684±0.002
	2	0.504	0.520	0.661±0.017	0.537±0.041	0.413	0.706±0.002
	3	0.627	0.647	0.526±0.010	0.484±0.005	0.500	0.791±0.003
	4	0.597	0.582	0.569±0.030	0.597±0.063	0.406	0.754±0.005
	5	0.535	0.549	0.524±0.022	0.466±0.016	0.428	0.630±0.002
	6	0.559	0.572	0.550±0.011	0.517±0.008	0.511	0.837±0.001
	7	0.644	0.629	0.528±0.037	0.548±0.016	0.554	0.617±0.005
	8	0.667	0.656	0.532±0.048	0.667±0.002	0.592	0.790±0.003
	9	0.701	0.741	0.425±0.025	0.712±0.012	0.627	0.905±0.001
	10	0.830	0.841	0.527±0.039	0.783±0.011	0.798	0.858±0.002
	11	0.597	0.580	0.464±0.024	0.627±0.007	0.537	0.820±0.002
	12	0.687	0.685	0.427±0.031	0.668±0.000	0.589	0.797±0.002
	13	0.650	0.646	0.454±0.007	0.526±0.001	0.574	0.583±0.001
	14	0.507	0.512	0.572±0.013	0.440±0.006	0.394	0.896±0.002
	15	0.635	0.628	0.488±0.015	0.568±0.001	0.556	0.665±0.003
	16	0.683	0.666	0.544±0.031	0.631±0.001	0.633	0.717±0.003
	17	0.717	0.737	0.364±0.023	0.730±0.010	0.667	0.911±0.003
	18	0.502	0.528	0.524±0.014	0.577±0.016	0.443	0.879±0.003
	19	0.575	0.584	0.503±0.010	0.555±0.007	0.530	0.849±0.001
	avg	0.626	0.631	0.505	0.588	0.547	0.770
Fashion-MNIST (32x32x1)	0	0.982	0.977	0.421±0.091	0.916±0.012	0.899	0.995±0.001
	1	0.903	0.899	0.551±0.035	0.718±0.005	0.819	0.954±0.001
	2	0.907	0.914	0.504±0.073	0.883±0.002	0.876	0.854±0.002
	3	0.942	0.907	0.570±0.067	0.873±0.036	0.912	0.860±0.002
	4	0.894	0.891	0.269±0.054	0.852±0.009	0.865	0.884±0.001
	5	0.918	0.885	0.705±0.097	0.871±0.000	0.896	0.924±0.012
	6	0.834	0.817	0.483±0.050	0.734±0.041	0.743	0.801±0.001
	7	0.988	0.987	0.835±0.114	0.981±0.000	0.972	0.975±0.002
	8	0.919	0.906	0.499±0.072	0.860±0.032	0.890	0.889±0.001
	9	0.990	0.986	0.340±0.030	0.971±0.003	0.971	0.974±0.001
	avg	0.928	0.917	0.518	0.866	0.884	0.911
CatsVsDogs (64x64x3)	0	0.504	0.552	0.434±0.005	0.471±0.017	0.507	0.886±0.002
	1	0.530	0.499	0.520±0.019	0.561±0.012	0.481	0.871±0.003
	avg	0.517	0.525	0.477	0.516	0.494	0.879

Generative Probabilistic Novelty Detection with Adversarial Autoencoders

- 観測されるデータは，Manifold $M \equiv f(z_i)$ 上のポイント x_i とノイズ ξ_i が加算されたものである
 - $i = 1, 2, \dots, N, \dots$
 - $f: \mathbb{R}^n \rightarrow \mathbb{R}^m$ (Encoder)
 - $g: \mathbb{R}^m \rightarrow \mathbb{R}^n$ (Decoder)
- ノイズは M に直行するようにポイントを動かす
- データを M の接ベクトル空間 T での座標から確率密度を算出する



$$\begin{aligned}
 p_X(\bar{x}) &= p_W(w) && \text{接ベクトル空間での座標でのpdf} \\
 &= p_w(w^{\parallel}, w^{\perp}) && \text{互いに独立} \\
 &= p_{w^{\parallel}}(w^{\parallel}) p_{w^{\perp}}(w^{\perp}) \\
 &&& \begin{array}{ll} T \text{ と parallel} & T \text{ と orthogonal} \\ \text{(manifold)} & \text{(noise)} \end{array}
 \end{aligned}$$